SAD Lab3

Izabela Siemieniuk

2026-04-08

Zadanie 1

W urnie znajduje się 8 kul ponumerowanych od 1 do 8. Losujemy jednocześnie 5 kul. Niech X oznacza największy spośród numerów kul w wylosowanej próbce. Wyznacz rozkład x (w ramce ddanych) oraz stwórz wykres tego rozkładu oraz jego dystrybuante. Można wykorzystać funkcję ecdf(). Wskazówka - korzytając z ecdf należy odpowiedio przygotować dane (próbkę) bazując na prawdopodbieństwie. Funkcja ecdf() to funckja wyznaczająca dystrybuantę empiryczną czy taką, która bazuje na próbce jaką mamy. Jest ona przybliżeniem dystrybuanty teoretycznej. chunk like this:

```
# combn(x, m, FUN = NULL, simplify = TRUE, ...)
komb <- combn(1:8, 5)

X <- apply(komb, 2, max)

tab <- table(X) #zlicza ile razy występuje każda wartość
tab
```

```
## X
##  5  6  7  8
##  1  5 15 35
```

```
px <- tab / sum(tab) #częstość/wszystkie

px
```

```
## X
##          5          6          7          8
## 0.01785714 0.08928571 0.26785714 0.62500000
```

```
barplot(px, main="Rozkład P(X=x)", xlab="x", ylab="P(X=x)", col=rgb(0.8,0.1,0.1,0.6))
```

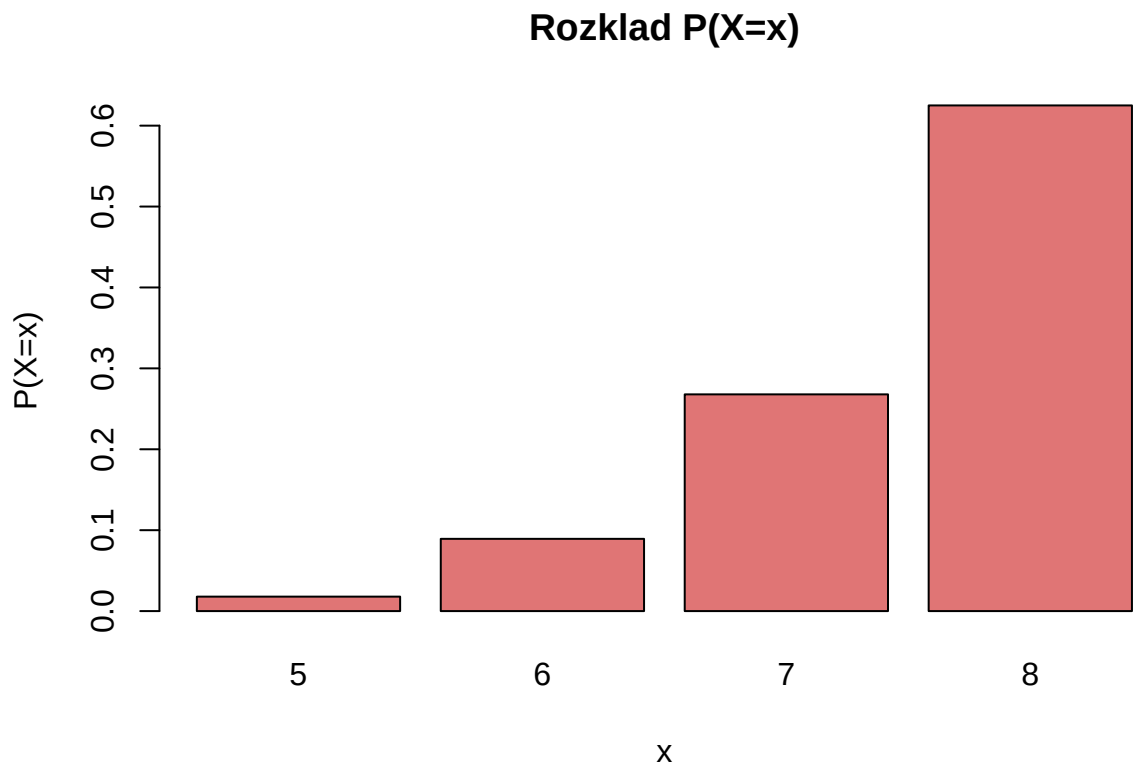


```r
Fx_emp <- ecdf(X)
plot(Fx_emp, main="Dystrybuanta empiryczna")
```

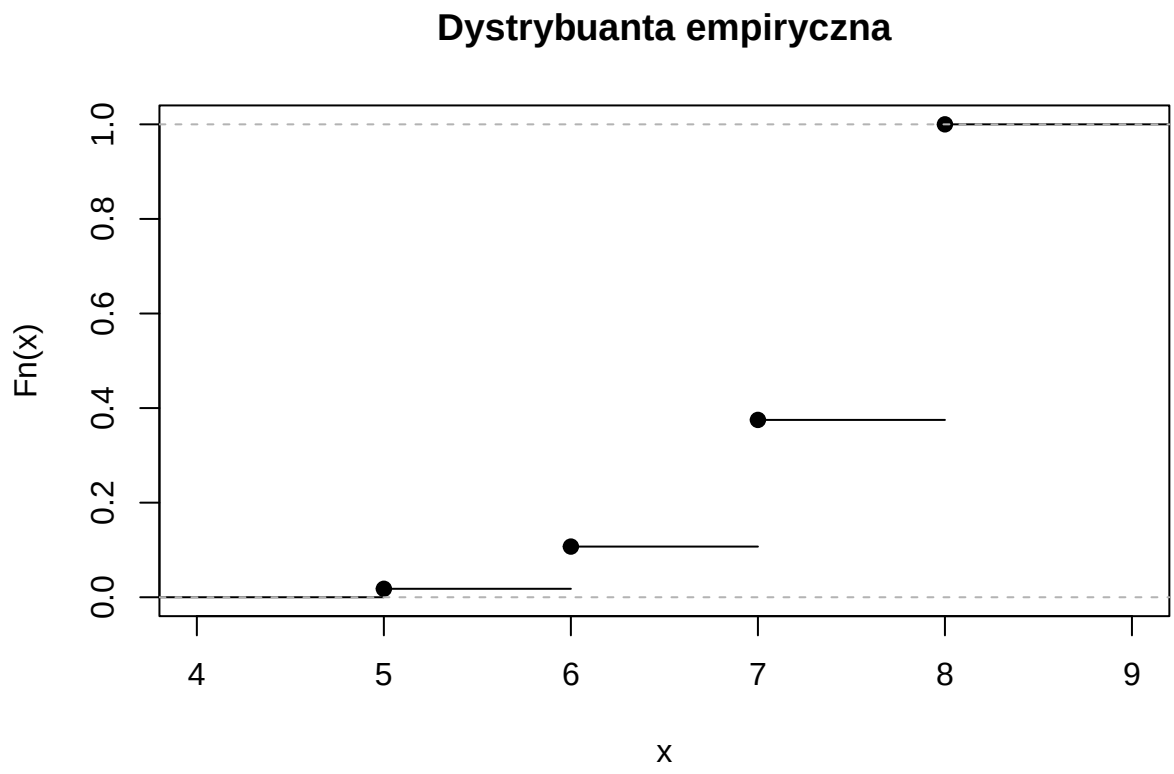

Zadanie 2

Wyznaczyć dla rozkładu normalnego o średniej 2 i odchyleniu standardowym 5 wartość funkcji gęstości w punkcie 3, wartość dystrybuanty w pukcie 7, podać kwantyl rzędu 4/5 i podać do powyższych przypadków interpretację. Powtórzyć to dla rozkładu t-studenta o 5 stopniach swobody

Rozkład normalny N(2,5)

```
# dnorm(x, mean = 0, sd = 1, log = FALSE)
# pnorm(q, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)
# qnorm(p, mean = 0, sd = 1, lower.tail = TRUE, log.p = FALSE)

dnorm(3, mean=2, sd=5) #wartość funkcji gęstości prawdopodobieństwa
```

```
## [1] 0.07820854
```

```
pnorm(7, mean=2, sd=5) #dystrybuanta, P(X <= 7)
```

```
## [1] 0.8413447
```

```
qnorm(0.8, mean=2, sd=5) # kwantyl 4/5 = 80%, wartość x taka, że P(X <= x) = 0.8
```

```
## [1] 6.208106
```

Rozkład T-Studenta o 5 stopniach swobody

```r
# Taka sama konwencja - d dla gęstości, p dla dystrybuanty, i q dla kwantyli

dt(3, df=5)
```

```
## [1] 0.01729258
```

```r
pt(7, df=5)
```

```
## [1] 0.9995416
```

```r
qt(0.8, df=5)
```

```
## [1] 0.9195438
```

Zadanie 3

Obliczyć P(X <= 1,5) oraz P(|X| < 2,5) jeżeli zmienna losowa X ma rozkład N(0,1) i N(2,1)

```r
# Rozkład 0, 1 więc nie musimy podawać parametrów
# 1. Dystrybuanta
pnorm(1.5)
```

```
## [1] 0.9331928
```

```r
# 2. Różnica dystrybuant
pnorm(2.5) - pnorm(-2.5)
```

```
## [1] 0.9875807
```

```r
# N(2,1)
pnorm(1.5, mean=2, sd=1)
```

```
## [1] 0.3085375
```

```r
pnorm(2.5, 2, 1) - pnorm(-2.5, 2, 1)
```

```
## [1] 0.6914591
```

Zadanie 4

Wyznaczyć następującę prawdopodbieństwa : P(x < 1), P(-1/2 <= x <= 1/2), P(x >= -1). Zakładamy, że X jest zmienną losową z rozkładu jednostajnego na przedziale [-3, 3], i druga opcja X jest z rozkładu wykładniczego z parametrem Lambda = 1.5, dla prawdopodobieńst: P(x < 1), P(12 <= x <= 32), P(x >= 4).

```r
# punif(0.5, min = 0, max = 1) rozkład jednostajny
punif(1, -3, 3)
```

```
## [1] 0.6666667
```

```r
punif(0.5, -3, 3) - punif(-0.5, -3, 3)
```

```
## [1] 0.1666667
```

```r
1 - punif(-1, -3, 3)
```

```
## [1] 0.6666667
```

```r
# pexp(x_dexp, rate = 5)   Rozkład wykładniczy
pexp(1, 1.5)
```

```
## [1] 0.7768698
```

```r
pexp(1.5, 1.5) - pexp(0.5, 1.5)
```

```
## [1] 0.3669673
```

```r
1 - pexp(4, 1.5)
```

```
## [1] 0.002478752
```

Zadanie 5

Reguła 3 sigma (68% wartośći z przedziału (-1,1) 95% z przedziału (-2,2), 99% z przedziału (-3,3)). Pokazać dla 1000 wartości (próbki) z rozkładu normalnego (oraz dla rozkładu ciągłego), że rzeczywiście tak jest. Pokazać to również dla rozkładu teoretycznego i porównać

```r
set.seed(42)
x <- rnorm(1000) # losujemy 100 wartości w celu symulacji

mean(abs(x) < 1) # mniej niż 68
```

```
## [1] 0.673
```

```r
mean(abs(x) < 2) #
```

```
## [1] 0.952
```

```r
mean(abs(x) < 3)
```

```
## [1] 0.995
```

```r
hist(x, probability=TRUE,
     main="Reguła 3 sigma",
     xlab="x",
     col=rgb(0.8,0.1,0.1,0.6))

abline(v=c(-1,1))
abline(v=c(-2,2))
abline(v=c(-3,3))
```

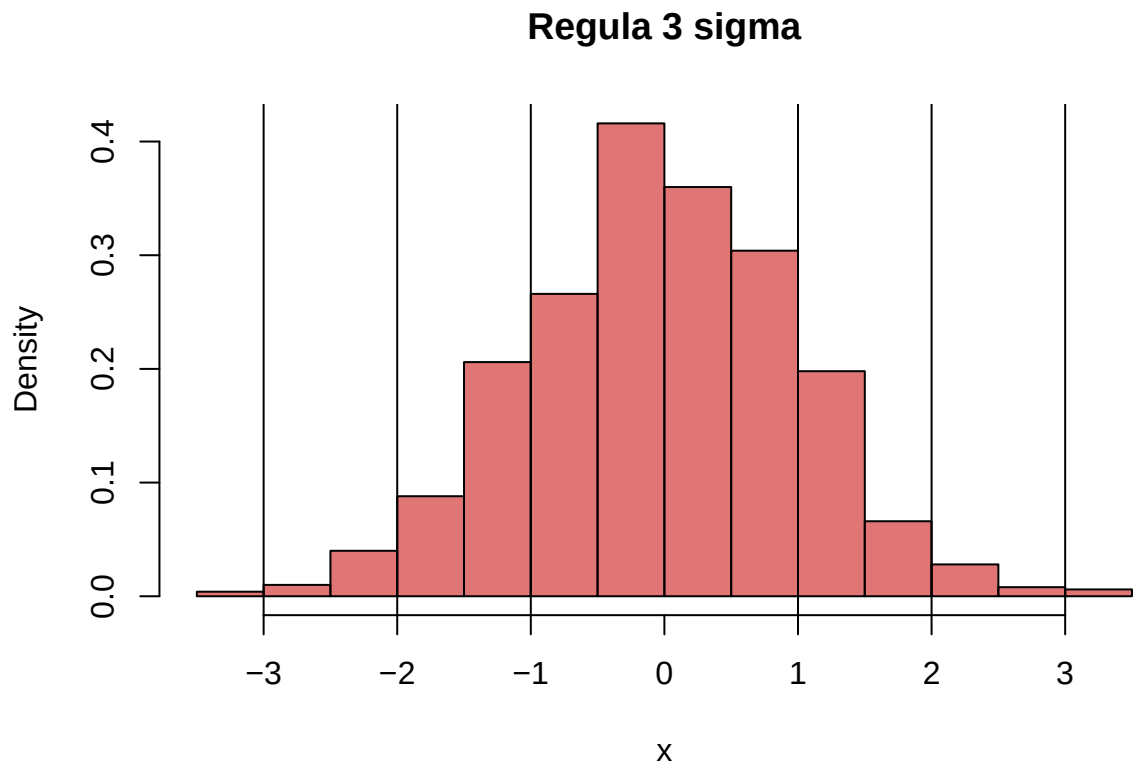


```r
# Rozkład teoretyczny
pnorm(1) - pnorm(-1)
```

```
## [1] 0.6826895
```

```r
pnorm(2) - pnorm(-2)
```

```
## [1] 0.9544997
```

```r
pnorm(3) - pnorm(-3)
```

```
## [1] 0.9973002
```

Wyniki empiryczne są bardzo zbliżone do teoretycznych, potwierdzają regułę 3 sigm. Różnice wynikają z losowości próby.

Zadanie 6

Narysować dystrybuanty oraz rozkłady teoretyczne i empiryczne dla rozkładów dyskretnych oraz dla rozkładów ciągłych. Następnie na podanej próbce oblicz średnią i wariancje dla każdego rozkładu i sprawdź czy zgadzają sie one z wartościami teoretycznymi. (link do rozkładów : https://stat.ethz.ch/R-manual/R-devel/library/stats/html/Distributions.html)

```
set.seed(123)
x_exp <- rexp(1000, rate=1.5) # Wybrano rozkłąd wykładniczy

plot(ecdf(x_exp), main="Dystrybuanta wykładnicza (empiryczna)",
     xlab="x", ylab="F(x)", col=rgb(0.8,0.1,0.1,0.6))

curve(pexp(x, rate=1.5), add=TRUE, lty=2) # Teoretyczna
```

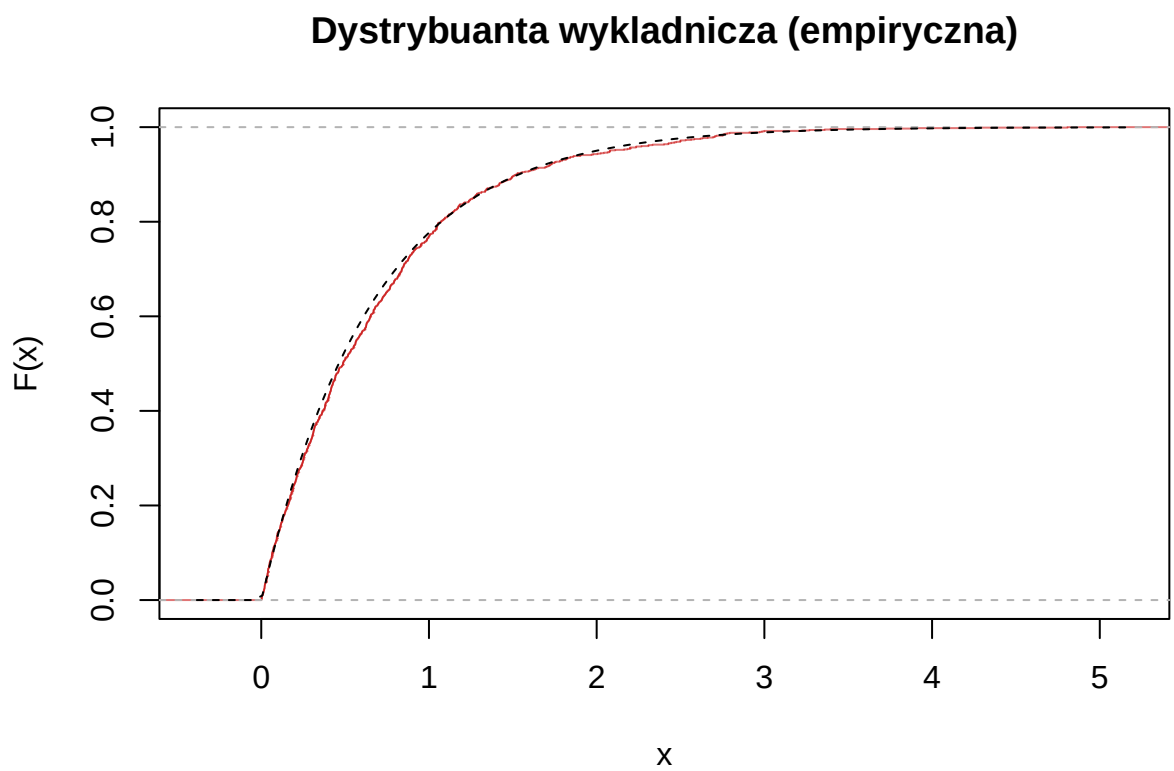


```
mean(x_exp)
```

```
## [1] 0.6866528
```

```
mean(x_exp) - 1/1.5
```

```
## [1] 0.01998618
```

```r
var(x_exp)
```

```
## [1] 0.448368
```

```r
var(x_exp) - 1/(1.5^2)
```

```
## [1] 0.003923605
```

```r
set.seed(123)
x_exp <- rexp(100, rate=1.5) # Wybrano rozkłąd wykładniczy

plot(ecdf(x_exp), main="Dystrybuanta wykładnicza (empiryczna)",
     xlab="x", ylab="F(x)", col=rgb(0.8,0.1,0.1,0.6))

curve(pexp(x, rate=1.5), add=TRUE, lty=2) # Teoretyczna
```

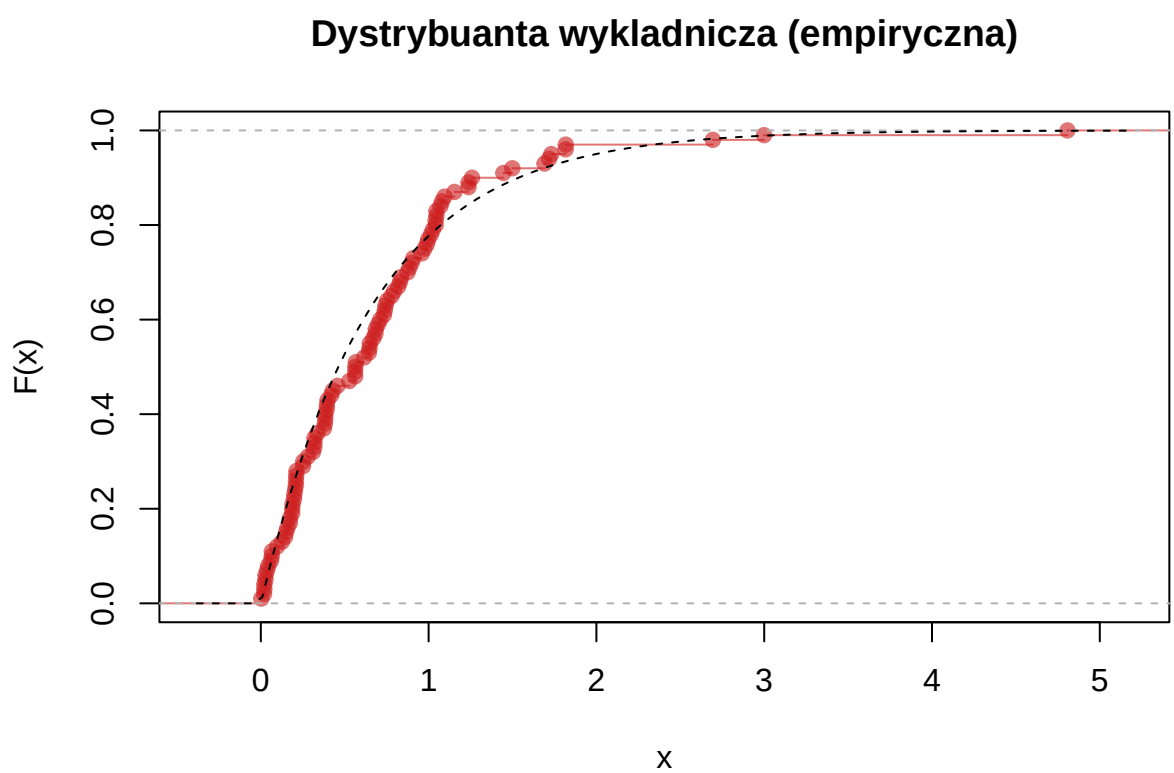


```r
mean(x_exp)
```

```
## [1] 0.6971458
```

```r
mean(x_exp) - 1/1.5 #1/lambda
```

```
## [1] 0.03047914
```

```r
var(x_exp)
```

```
## [1] 0.4794347
```

```r
var(x_exp) - 1/(1.5^2) # 1/lambda^2
```

```
## [1] 0.03499024
```

Wykonano podstawowe testy dla pojedynczego rozkładu wykładniczego. Sprawdzono dwie liczebności próby - 1000 i 100. Dla małych prób wyniki są bardziej podatne na losowe odchylenia, stąd wyższe błędy w porównaniu z wartościami teoretycznymi.

```r
set.seed(42)
n <- 1000


# rozkłady ciągłe
x_norm <- rnorm(n, mean = 0, sd = 1) # Normalny
x_unif <- runif(n, min = -2, max = 3) # jednostajny
x_exp  <- rexp(n, rate = 2) #wykładniczy

# rozkłady dyskretne
x_bern <- rbinom(n, size = 1, prob = 0.3) # Bernoulli
x_bin  <- rbinom(n, size = 10, prob = 0.5) # Binomial
x_poi  <- rpois(n, lambda = 4) # Poisson

salmon_col <- "#FA8072"
teal_col <- "#008080"


plot_discrete <- function(x, title) {
  probs <- prop.table(table(x))
  barplot(probs, main = paste("Empiryczne P(Y=y) dla", title),
          xlab = "Wartość y", ylab = "P(Y=y)", col = salmon_col)
}

plot_continuous <- function(x, title) {
  hist(x, prob = TRUE, main = paste("Histogram i gęstość dla", title), col = salmon_col)
  lines(density(x), col = teal_col, lwd=2)
}

# ciągłe
plot_continuous(x_norm, "N(0,1)")
curve(dnorm(x,0,1), add=TRUE, col=salmon_col, lwd=2)
```

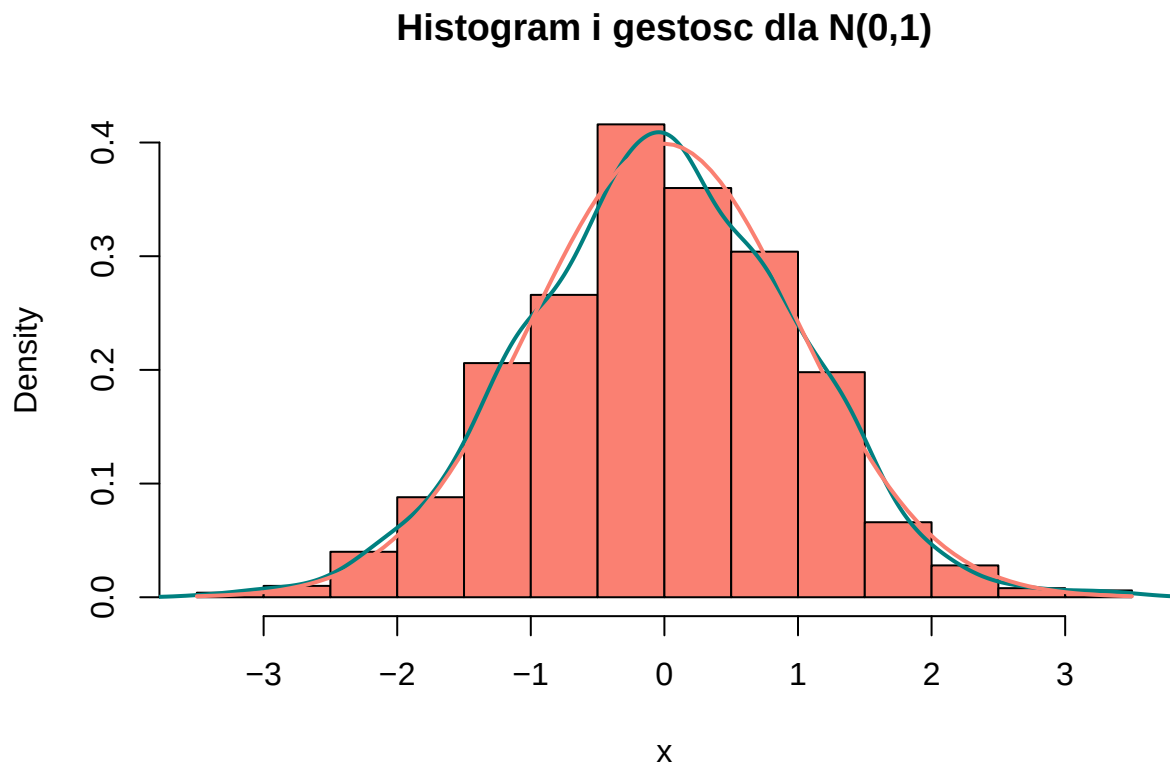


```
plot_continuous(x_unif, "U(-2,3)")
curve(dunif(x,-2,3), add=TRUE, col=salmon_col, lwd=2)
```

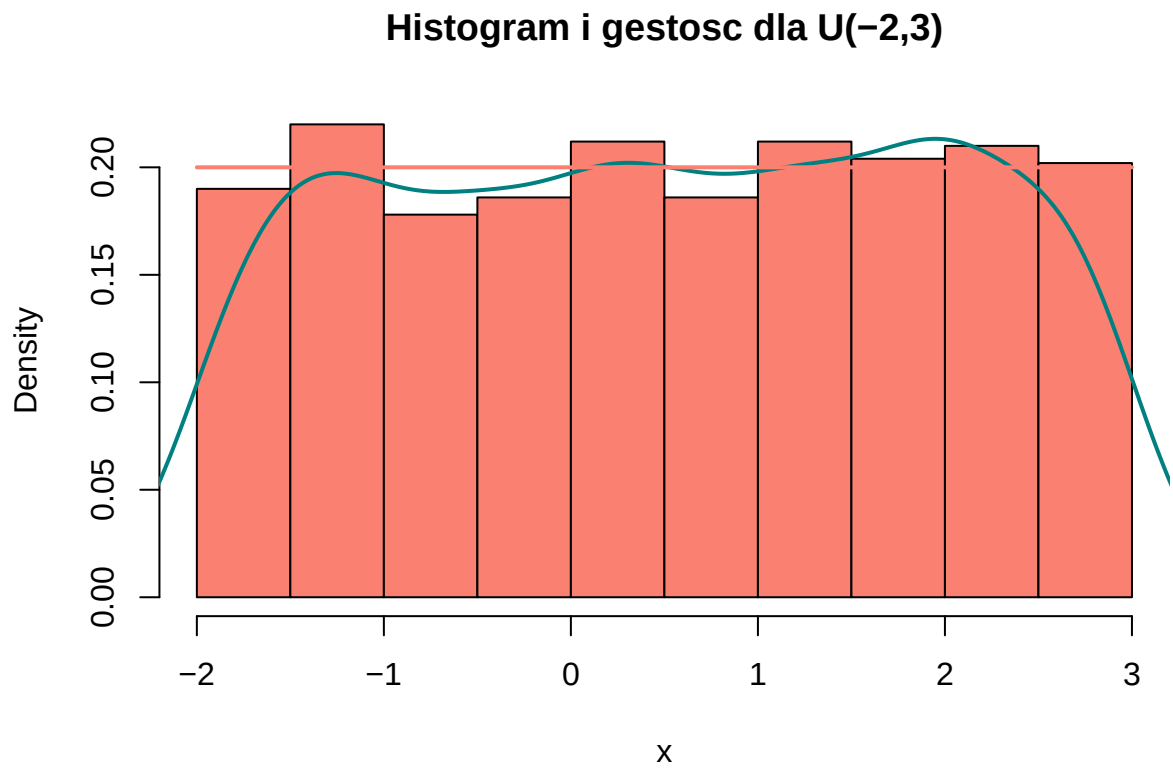


```
plot_continuous(x_exp, "Exp(lambda=2)")
curve(dexp(x, rate = 2), add=TRUE, col=salmon_col, lwd=2)
```

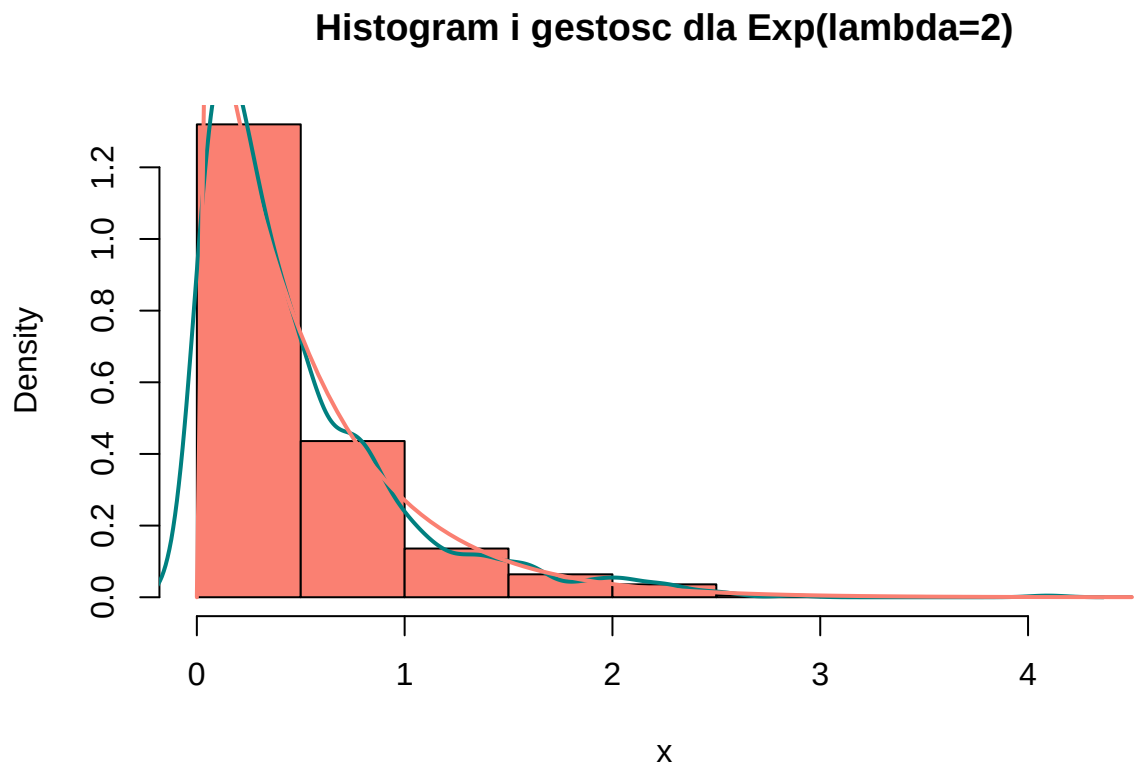


```r
# dystrybuanta empiryczna vs teoretyczna
plot(ecdf(x_norm), main="Dystrybuanta N(0,1)")
curve(pnorm(x,0,1), add=TRUE, col=teal_col, lwd=2)
```

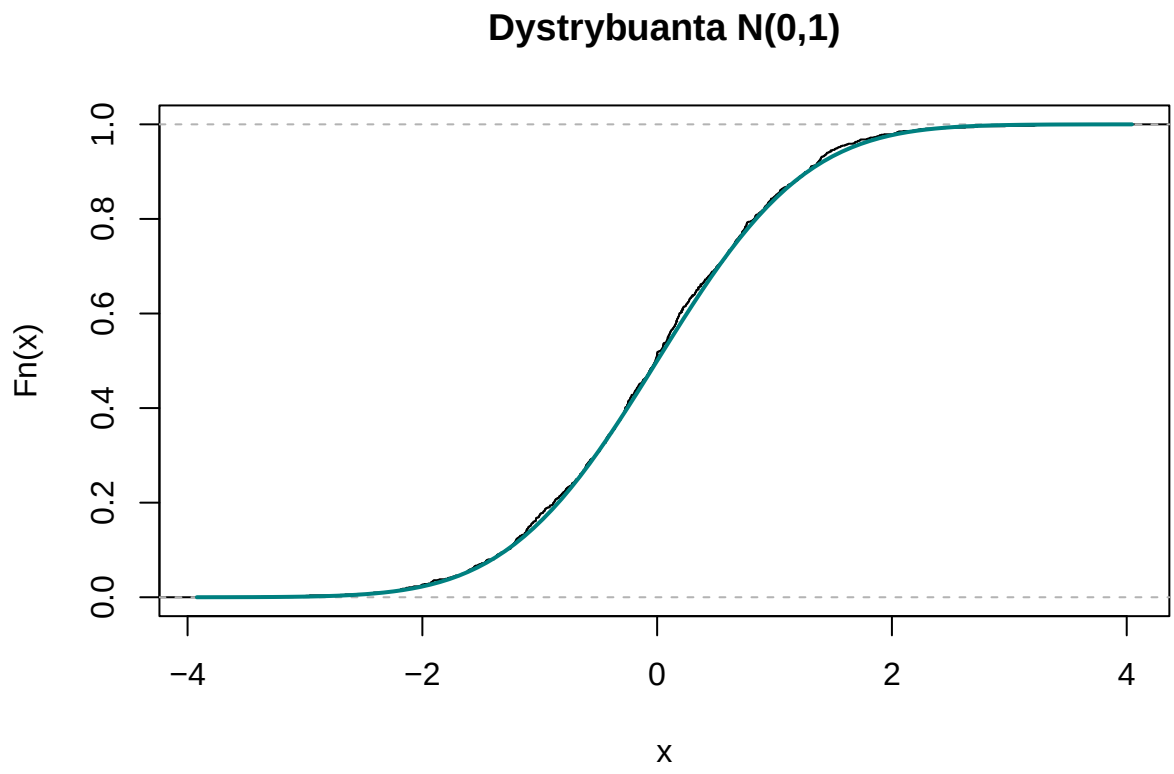


```r
plot(ecdf(x_unif), main="Dystrybuanta U(-2,3)")
curve(punif(x,-2,3), add=TRUE, col=teal_col, lwd=2)
```

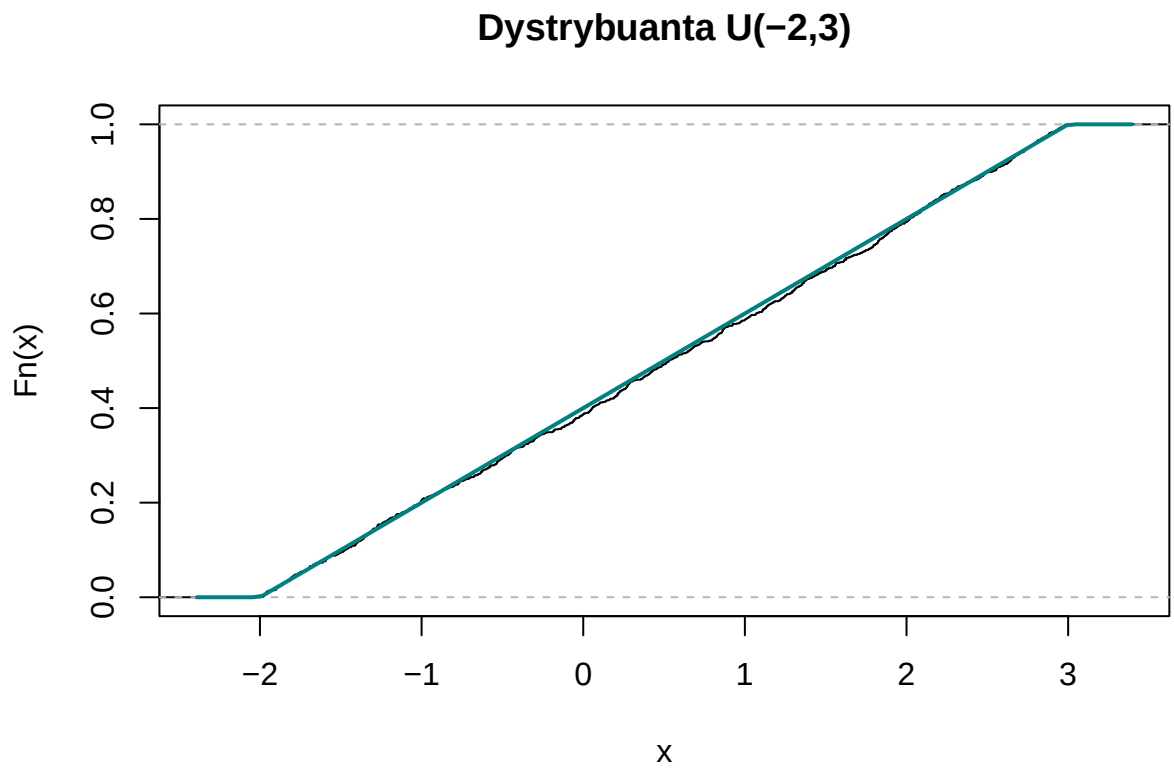


```
plot(ecdf(x_exp), main="Dystrybuanta Exp(lambda=2)")
curve(pexp(x, rate = 2), add=TRUE, col=teal_col, lwd=2)
```

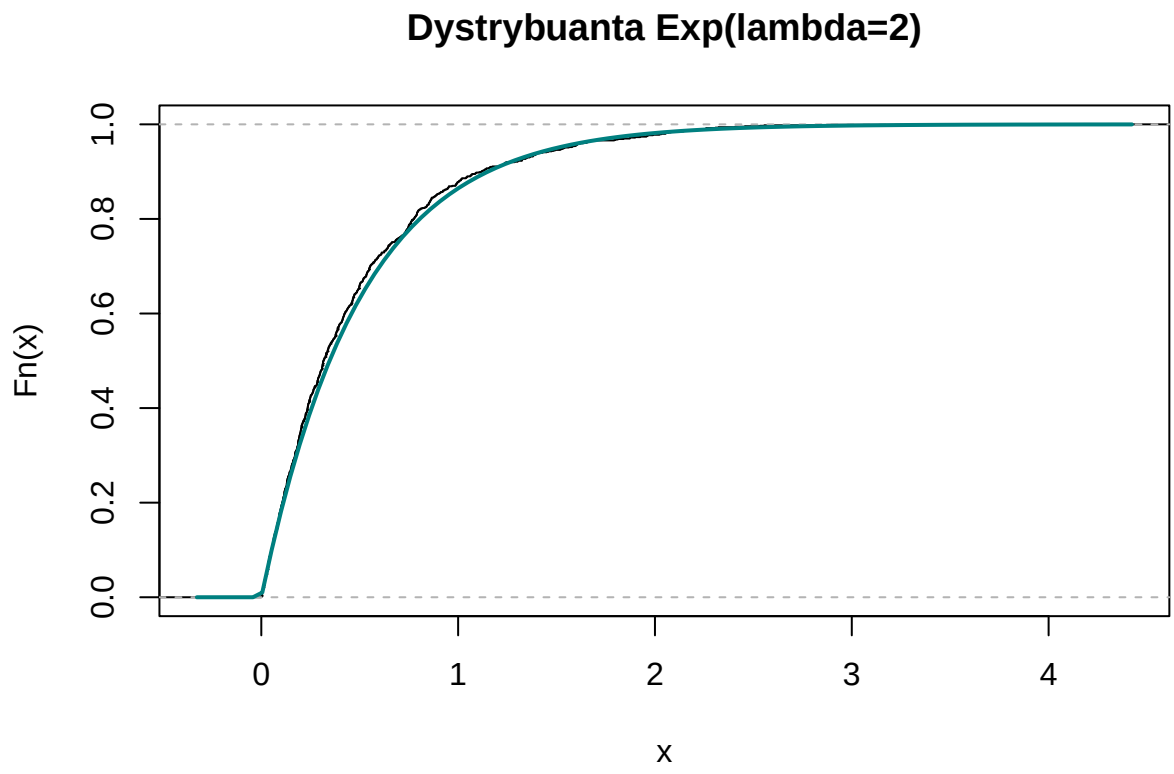


```r
# dyskretne
plot_discrete(x_bern, "Bernoulli(p=0.3)")
```

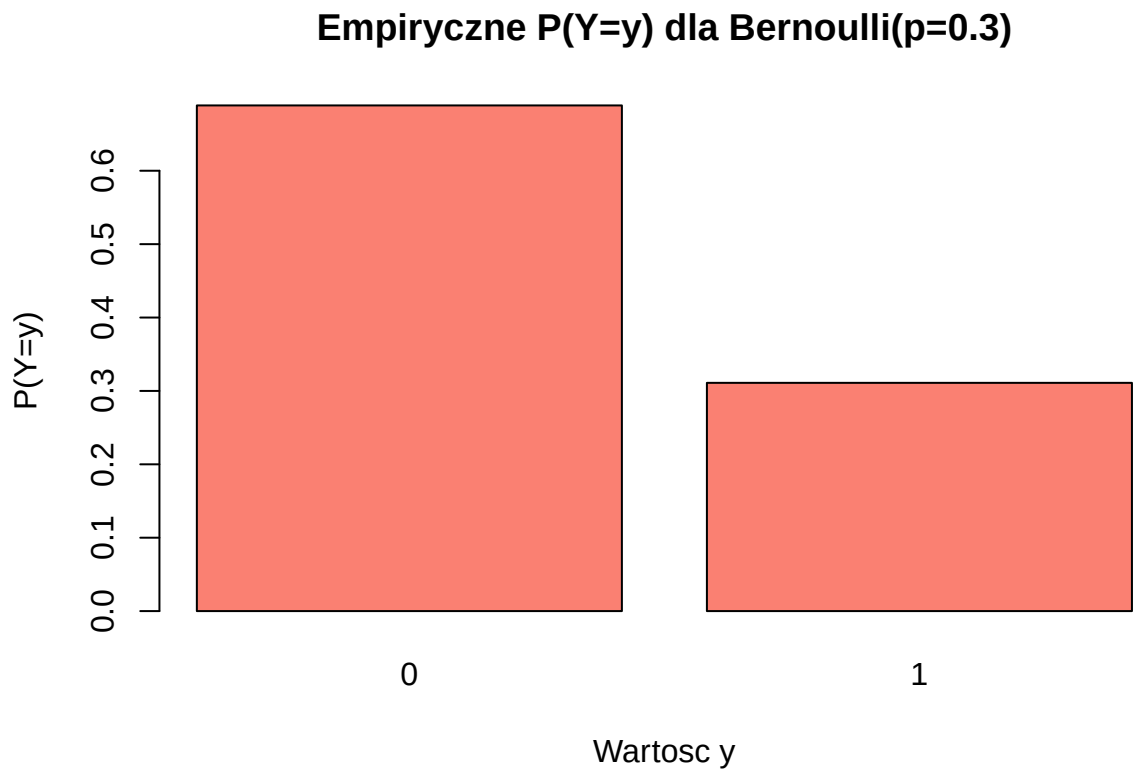


```r
plot_discrete(x_bin, "Binomial(n=10, p=0.5)")
```

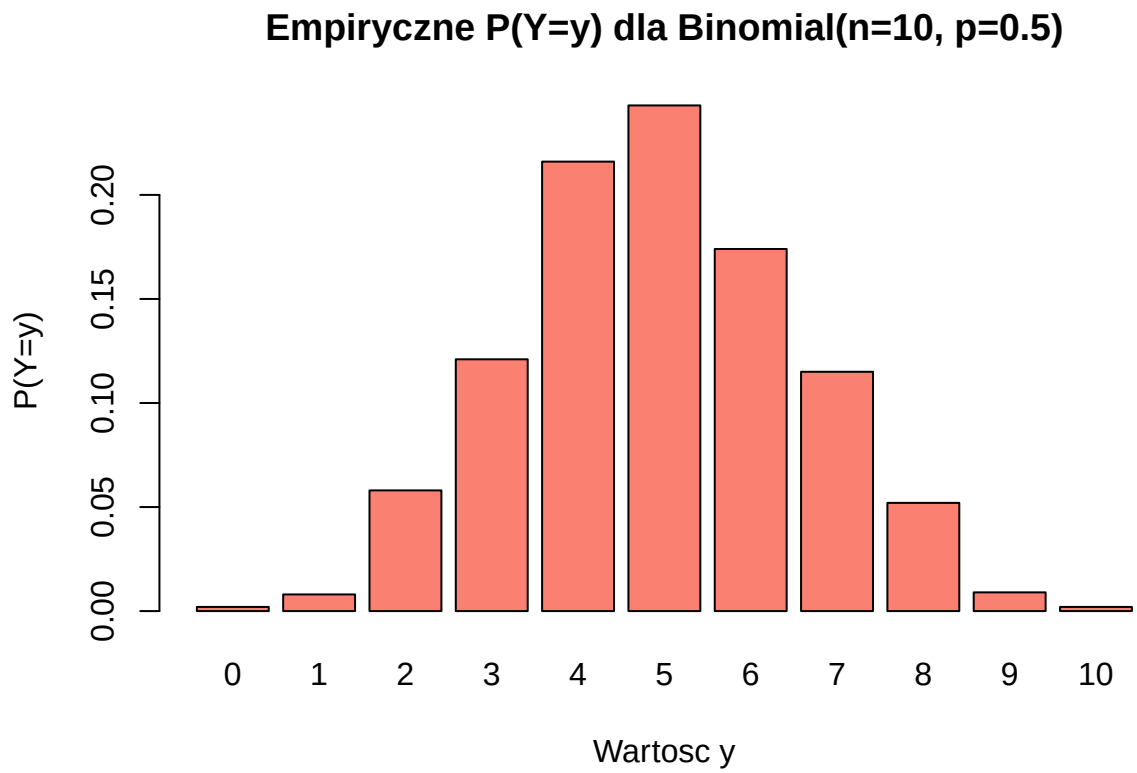


```
plot_discrete(x_poi, "Poisson(lambda=4)")
```

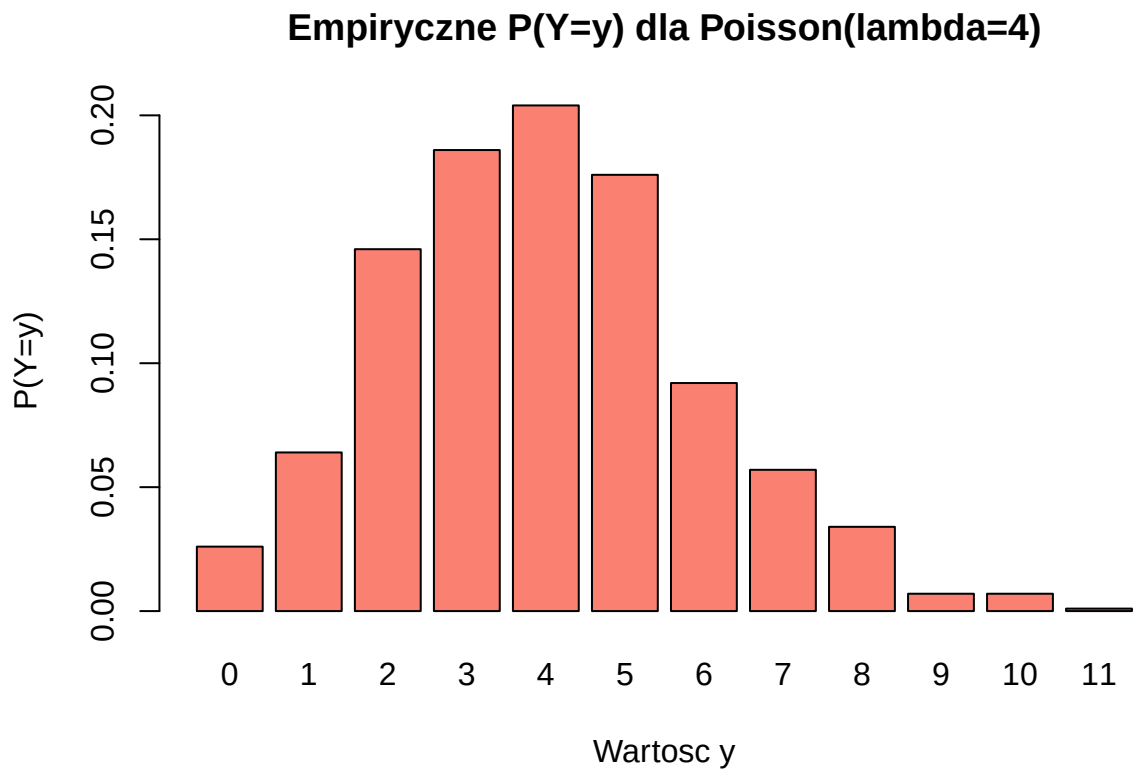


```r
df <- data.frame(
  Rozklad = c("N(0,1)","U(-2,3)","Exp(2)","Bernoulli","Binomial","Poisson"),
  Emp_Mean = c(mean(x_norm), mean(x_unif), mean(x_exp),
               mean(x_bern), mean(x_bin), mean(x_poi)),
  Emp_Var  = c(var(x_norm), var(x_unif), var(x_exp),
               var(x_bern), var(x_bin), var(x_poi))
)

df$Theo_Mean <- c(0, (-2+3)/2, 1/2,
                  0.3, 10*0.5, 4)

df$Theo_Var <- c(1, (3+2)^2/12, 1/2^2,
                 0.3*(1-0.3), 10*0.5*0.5, 4)

df$Mean_Error <- df$Emp_Mean - df$Theo_Mean
df$Var_Error  <- df$Emp_Var - df$Theo_Var

print(df)
```

```
##     Rozklad    Emp_Mean   Emp_Var Theo_Mean Theo_Var  Mean_Error    Var_Error
## 1    N(0,1) -0.02582443 1.0050488       0.0 1.000000 -0.02582443  0.005048830
## 2   U(-2,3)  0.52748505 2.0954775       0.5 2.083333  0.02748505  0.012144213
## 3    Exp(2)  0.48151116 0.2461045       0.5 0.250000 -0.01848884 -0.003895522
## 4 Bernoulli  0.31100000 0.2144935       0.3 0.210000  0.01100000  0.004493493
## 5  Binomial  4.93200000 2.6940701       5.0 2.500000 -0.06800000  0.194070070
## 6   Poisson  3.97700000 3.8423133       4.0 4.000000 -0.02300000 -0.157686687
```

Dla wszystkich rozkładów różnice są bardzo małe a rozklady empiryczne zbliżone do tych teoretycznych, co również można było zobacyzć na wykresach